

线性代数入门

梁鑫 田垠 杨一龙 编著

蔚 辉

清华大学丘成桐数学科学中心

报告中均非完整定义或准确表述。具体细节请参考教材。

Definition

集合 X 到 Y 的映射

$$\begin{aligned} f: \quad X &\rightarrow Y, \\ x &\mapsto y = f(x). \end{aligned}$$

三种特殊情形:

- ① 单射: 零空间/核 $\mathcal{N}(f) = 0$.
- ② 满射: 列空间/像集 $\mathcal{R}(f) = \mathcal{C}(f)$.
- ③ 双射: f 既是单射又是满射。

Definition

集合 X 到 Y 的映射

$$\begin{aligned} f: \quad X &\rightarrow Y, \\ x &\mapsto y = f(x). \end{aligned}$$

三种特殊情形:

- ① 单射: 零空间/核 $\mathcal{N}(f) = 0$.
 - ② 满射: 列空间/像集 $\mathcal{R}(f) = \mathcal{C}(f)$.
 - ③ 双射: f 既是单射又是满射。
- $X = Y$: 变换。
- 映射的复合: $g \circ f(x) = g(f(x))$ 。
- 逆映射: $f^{-1}f(x) = x \quad \forall x \in X$ 。

- 1 数域 $\mathbb{F} \subset \mathbb{C}$.
- 2 八条运算法则。
- 3 子空间：对加法和数乘封闭。
- 4 列空间 $\mathcal{R}(A) \perp \mathcal{N}(A^T)$, $\mathcal{N}(A) = \mathcal{N}(A^T A)$ 及其衍生等式。
- 5 $\mathcal{M}_1 \cap \mathcal{M}_2$, $\mathcal{M}_1 + \mathcal{M}_2$, $\mathcal{M}_1 \oplus \mathcal{M}_2$.

设 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 和 $\mathbf{t}_1, \dots, \mathbf{t}_n$ 分别是 n 维线性空间 $\mathcal{U}$ 的一组基。应有

$$(\mathbf{t}_1, \dots, \mathbf{t}_n) = (\mathbf{e}_1, \dots, \mathbf{e}_n)T.$$

其中 $T \in \mathbb{F}^{m \times n}$ 是过渡矩阵，必定可逆。

- 基变换，坐标系变换，变量代换。
- 转化为一组标准正交基。

给定数域 $\mathbb{F}$ 上的线性空间 $\mathcal{U}$ 和 $\mathcal{V}$. 考虑从 $\mathcal{U}$ 到 $\mathcal{V}$ 的映射 f .

Definition

称 f 为从 $\mathcal{U}$ 到 $\mathcal{V}$ 的线性映射, 如果线性运算满足可加性和齐次性:

- ① 任取 $\mathbf{x}, \mathbf{x}' \in \mathcal{U}$, 有 $f(\mathbf{x} + \mathbf{x}') = f(\mathbf{x}) + f(\mathbf{x}')$;
- ② 任取 $\mathbf{x} \in \mathcal{U}, k \in \mathbb{F}$, 有 $f(k\mathbf{x}) = kf(\mathbf{x})$,

► 表示矩阵与线性映射一一对应。

设 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 和 $\mathbf{i}_1, \dots, \mathbf{i}_m$ 分别是 n 维线性空间 $\mathcal{U}$ 和 m 维线性空间 $\mathcal{V}$ 的一组基。

$$\mathbf{x} = x_1\mathbf{e}_1 + \dots + x_n\mathbf{e}_n = (\mathbf{e}_1, \dots, \mathbf{e}_n)\vec{x}.$$

$$f(\mathbf{x}) = \left(f(\mathbf{e}_1), \cdots, f(\mathbf{e}_n)\right) \vec{x} = \left(\mathbf{i}_1, \cdots, \mathbf{i}_m\right) F \vec{x},$$

其中表示矩阵为 $F \in \mathbb{F}^{m \times n}$.

- 抽象线性映射 f 的核、像集、特征对等问题可以转化为表示矩阵 F 的对应问题。

取 $\mathbb{R}^n$ 和 $\mathbb{R}^m$ 的标准基, 有 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性映射 f :

$$f(\mathbf{x}) = A\mathbf{x},$$

其中表示矩阵 $A = [\mathbf{a}_1, \dots, \mathbf{a}_n] \in \mathbb{R}^{m \times n}$, 且 $f(\mathbf{e}_i) = \mathbf{a}_i$, $1 \leq i \leq n$.

- 初等矩阵：对换 P_{ij} ，倍乘 $E_{ii;k}$ ，倍加 $E_{ji;k}$ 。
- 初等变换不改变矩阵的秩。
- 倍加变换不改变矩阵的行列式函数值。
- 任何矩阵都可通过初等行变换化为阶梯形或唯一的行简化阶梯形。
- 使用阶梯形或行简化阶梯形求解线性方程组和进行基扩充。
- 分块矩阵的设计和使用：分块初等矩阵。

Definition

任意 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$:

$$\mathbf{x}^T \mathbf{y} = \sum_{i=1}^N x_i y_i.$$

- ▶ 向量长度 $\|\mathbf{x}\| = (\mathbf{x}^T \mathbf{x})^{\frac{1}{2}} = \left(\sum_{i=1}^N x_i^2 \right)^{\frac{1}{2}}.$
- ▶ $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}_n.$
- ▶ 非零向量 $\mathbf{x}, \mathbf{y}$ 正交: $\mathbf{x}^T \mathbf{y} = 0.$

- ① $\mathbb{R}^m$ 的标准基: $\mathbf{e}_1, \dots, \mathbf{e}_m$.
- ② 一组基 $\mathbf{a}_1, \dots, \mathbf{a}_s \rightarrow$ Gram-Schmidt 正交化
 $\rightarrow$ 一组标准正交基 $\mathbf{q}_1, \dots, \mathbf{q}_s$.

$$[\mathbf{a}_1 \cdots \mathbf{a}_s] = [\mathbf{q}_1 \cdots \mathbf{q}_s][\mathbf{r}_1 \cdots \mathbf{r}_s] = [\mathbf{q}_1 \cdots \mathbf{q}_s] \begin{bmatrix} r_{11} & \cdots & r_{1s} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & r_{ss} \end{bmatrix}$$

按列对应相等:

$$\begin{aligned} \mathbf{a}_1 &= r_{11}\mathbf{q}_1, \\ \mathbf{a}_2 &= r_{12}\mathbf{q}_1 + r_{22}\mathbf{q}_2, \\ &\dots \end{aligned}$$

利用 $\mathbf{q}_i$ 的正交性和单位化, 依次求解 $\mathbf{r}_i$ 和 $\mathbf{q}_i$: $r_{ij} = \mathbf{q}_i^T \mathbf{a}_j$.

- ③ 列不满秩情形下的Gram-Schmidt 正交化。

- ❶ $Q \in \mathbb{R}^{m \times m} : \quad Q^T Q = I_m.$
- ❷ 保距: $\|Q\mathbf{x}\| = \|\mathbf{x}\| \quad \forall \mathbf{x} \in \mathbb{R}^m.$
- ❸ 保内积: $(Q\mathbf{x})^T (Q\mathbf{y}) = \mathbf{x}^T \mathbf{y}.$
- ❹ 旋转变换 R_θ 和反射变换 $H_{\mathbf{v}} = I_m - 2\mathbf{v}\mathbf{v}^T$ with $\|\mathbf{v}\| = 1$ 。
- ❺ 列正交矩阵 Q_1 , 扩充出 Q_2 , 得到正交矩阵 Q , i.e., 子空间的一组标准正交基扩充成全空间 $\mathbb{R}^m$ 的一组标准正交基。

- $P_{\mathcal{M}}$: 投影到子空间 $\mathcal{M}$ 的正交投影线性变换, 或正交投影矩阵。
- $P_{\mathcal{M}}^2 = P_{\mathcal{M}}^T = P_{\mathcal{M}}$.
- $\forall \mathbf{a} \in \mathbb{R}^m$, 有唯一分解:

$$\mathbf{a} = \mathbf{a}_1 + \mathbf{a}_2 \quad \text{with } \mathbf{a}_1 = P_{\mathcal{M}}\mathbf{a} \in \mathcal{M}, \quad \mathbf{a}_2 \in \mathcal{M}^{\perp}.$$

- $\mathcal{M} = \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_r)$, 则有 $P_{\mathcal{M}} = Q_r Q_r^T$,

$$\mathbf{a}_1 = P_{\mathcal{M}}\mathbf{a} = Q_r Q_r^T \mathbf{a} = \sum_{j=1}^r (\mathbf{q}_j^T \mathbf{a}) \mathbf{q}_j.$$

- $\mathbf{a}$ 到子空间 $\mathcal{M}$ 的最短距离:

$$\|\mathbf{a} - P_{\mathcal{M}}\mathbf{a}\| = \min_{\tilde{\mathbf{a}} \in \mathcal{M}} \|\mathbf{a} - \tilde{\mathbf{a}}\|.$$

Definition

$$\delta(\mathbf{a}_1, \dots, \mathbf{a}_n) = \delta(A) = \det(A) = |A|.$$

❶ 多线性:

$$\delta(\dots, k\mathbf{a}_i + k'\mathbf{a}'_i, \dots) = k\delta(\dots, \mathbf{a}_i, \dots) + k'\delta(\dots, \mathbf{a}'_i, \dots).$$

❷ 列反对称性: $\delta(\dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots) = -\delta(\dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots)$

❸ 单位化条件: $\delta(I_n) = 1$.

- 倍加变换不改变行列式。
- 上（下）三角（分块）矩阵的行列式。
- A 可逆。 $\iff \det(A) \neq 0$.

- $\det(A) = a_{1j}C_{1j} + \cdots + a_{nj}C_{nj}$.
- $\mathbf{a}_i^T \mathbf{c}_j = \begin{cases} \det(A) & \text{if } i = j, \\ 0 & \text{if } i \neq j, \end{cases}$ with $\mathbf{c}_j = [C_{1j} \cdots C_{nj}]^T$.
- $A^{-1} = \frac{C^T}{\det(A)}$, 其中伴随矩阵 $C^T = [\mathbf{c}_1 \cdots \mathbf{c}_n]^T$.
- Cramer 法则. $A\mathbf{x} = \mathbf{b}$ 的解若存在, 则有

$$x_i = \frac{\det(B_i)}{\det(A)} \text{ for } i = 1, \dots, n.$$

$A\mathbf{x} = \lambda\mathbf{x} \iff (\lambda I_n - A)\mathbf{x} = \mathbf{0}$ 有非零解。

❶ λ 是特征多项式

$$p_A(\lambda) = \det(\lambda I_n - A) = \lambda^n - \text{trace}(A)\lambda^{n-1} + \cdots + (-1)^n \det(A)$$

的 n 个复根。

❷ Hamilton-Cayley 定理: $p_A(A) = O$.

❸ $\mathbf{x}$ 是特征子空间 $\mathcal{N}(\lambda I_n - A)$ 中的任意非零向量。

❹ 不同特征值对应的特征向量线性无关。

❺ 特征值的代数重数和几何重数。

❻ 单特征值, 半单特征值和亏损特征值。

Definition

$\exists \sigma \in \mathbb{R}$, 和非零向量 $\mathbf{x} \in \mathbb{R}^n, \mathbf{y} \in \mathbb{R}^m$, s.t.

$$A\mathbf{x} = \sigma\mathbf{y}, \quad A^T\mathbf{y} = \sigma\mathbf{x}.$$

A 有 $r = \text{rank}(A)$ 个正奇异值, 从大到小排序, 和 AA^T 或 A^TA 的 r 个正特征值一一对应:

$$\sigma_i = \sqrt{\lambda_i(AA^T)} = \sqrt{\lambda_i(A^TA)} \quad \text{for } i = 1, \dots, r.$$

- ① n 阶实矩阵 A 正定: $\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \text{ 非零 } \mathbf{x} \in \mathbb{R}^n$.
- ② 实对称矩阵 A 正定的等价结论:
 - $\lambda_i(A) > 0$ for $i = 1, \dots, n$.
 - $\exists$ 可逆 T , s.t. $A = TT^T$.
 - $A = LDL^T$, 其中对角矩阵 D 的对角元素都 > 0 , L 为单位下三角矩阵.
 - 顺序主子式都为正。
 - 顺序主子阵都正定。
- ③ 实对称矩阵的Cholesky 分解: $A = LL^T$, 其中 L 为下三角矩阵。
- ④ A 半正定的等价结论。

$A \in \mathbb{R}^{m \times n}$ with $m \geq n$, 存在 QR 分解:

$$A = QR = [Q_1 \quad Q_2] \begin{bmatrix} R_1 \\ O \end{bmatrix} = Q_1 R_1.$$

其中 Q_1 是 $m \times n$ 列正交矩阵, R_1 是 n 阶对角元素非负的上三角矩阵。
当 A 可逆时, R_1 的对角元素可全部取为正。

- 1 Gram-Schmidt 正交化: $A = Q_1 R_1$ with $\text{rank}(A) \leq n$.
- 2 扩充出 Q_2 .
- 3 补足零元素, 由 R_1 得到 R .
- 4 $\text{rank}(A) = r$: 得到列空间 $\mathcal{R}(A)$ 的一组标准正交基 Q_r , 用于计算正交投影矩阵 $P_A = Q_r Q_r^T$.

- 1 $A \in \mathbb{C}^{n \times n}$ 可对角化: $\exists$ 可逆 X 和对角 Λ , s.t. A 有谱分解 $A = X\Lambda X^{-1}$.
- 2 Λ : n 个特征值。 X : 对应的 n 个线性无关的特征向量。
- 3 A 可对角化。 $\iff A$ 的特征值都半单。
- 4 实对称矩阵的特征值都是实且半单。互异特征值对应的特征向量正交。
- 5 实对称矩阵总是有谱分解: $A = Q\Lambda Q^T$, 其中 Q 正交。

$$\textcircled{1} \quad A = U\Sigma V^T = U_r \Sigma_r V_r^T = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$

► 实对称矩阵的谱分解: $A^T A = V \Lambda V^T$ 或 $AA^T = U \Lambda U^T$.

► 得到 Σ 和 $V = [V_r \ V_2]$

► $U_r = AV_r^T \Sigma_r^{-1}$.

► 扩充出 U_2 , 得到 $U = [U_r \ U_2]$.

$\textcircled{2}$ 四个子空间 $\mathcal{R}(A), \mathcal{N}(A), \mathcal{R}(A^T), \mathcal{N}(A^T)$ 与 U 和 V 的关联。

$\textcircled{3}$ Moore-Penrose 广义逆: $A^+ = V_r \Sigma_r^{-1} U_r^T$.

- 记 P_A 为投影到 A 的列空间 $\mathcal{R}(A) = \mathcal{C}(A)$ 的正交投影矩阵:

$\forall \mathbf{b} \in \mathbb{R}^m$, 有唯一分解:

$$\mathbf{b} = \mathbf{b}_1 + \mathbf{b}_2 = P_A \mathbf{b} + P_{A^\perp} \mathbf{b}.$$

其中, $\mathbf{b}_1 = P_A \mathbf{b} \in \mathcal{R}(A)$, $\mathbf{b}_1^T \mathbf{b}_2 = 0$.



$$\|\mathbf{b} - P_A \mathbf{b}\| = \min_{\tilde{\mathbf{b}} \in \mathcal{R}(A)} \|\mathbf{b} - \tilde{\mathbf{b}}\|.$$

$\forall \tilde{\mathbf{b}} \in \mathcal{R}(A)$, 一定存在 $\tilde{\mathbf{x}} \in \mathbb{R}^n$, 使得 $\tilde{\mathbf{b}} = A\tilde{\mathbf{x}}$:

$$\|\mathbf{b} - A\mathbf{x}\| = \min_{\tilde{\mathbf{x}} \in \mathbb{R}^n} \|\mathbf{b} - A\tilde{\mathbf{x}}\|$$

$\min_{\tilde{\mathbf{x}} \in \mathbb{R}^n} \|\mathbf{b} - A\tilde{\mathbf{x}}\| \iff A\mathbf{x} = P_A\mathbf{b}.$ 总是有解，但不一定唯一。

► 正则化方法。

$\mathbf{x}$ 是最小二乘解。 $\iff A^T A\mathbf{x} = A^T \mathbf{b}.$ (解可能不唯一)

► QR 分解。

• $\text{rank}(A) = n$, 即 A 列满秩时,

$\mathbf{x}$ 是最小二乘解。 $\iff R_1\mathbf{x} = Q_1^T\mathbf{b}.$

• $\text{rank}(A) = r < n$:

$P_A = U_r U_r^T \Rightarrow U_r \Sigma_r V_r^T \mathbf{x} = U_r U_r^T \mathbf{b}.$ (解不唯一)

最小二乘解中长度最小的解: $\mathbf{x} = V_r \Sigma_r^{-1} U_r^T \mathbf{b} = A^+ \mathbf{b}.$

存在对应的可逆矩阵。

❶ 左相抵: $A = XB = PLU$.

❷ 相抵: $A = XBY = XD_rY$.

❸ 相似: $A = XBX^{-1} = XTX^{-1} = XJX^{-1} \in \mathbb{C}^{n \times n}$. J 为Jordan 块构成的对角分块矩阵。

❹ 正交相似: $A = QBQ^T$, 其中 Q 正交. 实对称 $A = Q\Lambda Q^T$.

❺ 合同: $A = XTX^T = XJX^T$. Sylvester 惯性定律。

❻ 对应的标准形和不变量。

给定非零 $\mathbf{x}$, 其关于方阵 A 的Rayleigh 商为 $\frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$.

实对称 A :

- 做特征值排序 $\lambda_1 \geq \dots \geq \lambda_n$.
- 取其正交单位特征向量组 $\mathbf{q}_1, \dots, \mathbf{q}_n$. 有:

$$\lambda_1 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}; \quad \lambda_i = \max_{\substack{\mathbf{x} \neq \mathbf{0} \\ \mathbf{x} \perp \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_{i-1})}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \quad \text{for } i = 2, \dots, n.$$

$$\lambda_n = \min_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}; \quad \lambda_i = \min_{\substack{\mathbf{x} \neq \mathbf{0} \\ \mathbf{x} \in \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_{i-1})}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \quad \text{for } i = 1, \dots, n-1.$$

1

$$\begin{aligned}\|A\| &= \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\| \\ &= \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_{\max}(A A^T)} \\ &= \sigma_{\max}(A) = \sigma_1.\end{aligned}$$

2

低秩逼近。

$$\|A - A_k\| = \min_{\text{rank}(B) \leq k} \|A - B\| = \sigma_{k+1},$$

其中 $k < r$, $A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$.