



线性代数之矩阵求导

线性代数L小组

段钰含 江昊源 廖敏辰 刘景浩 原泽宇 张芝源

一. 函数与标量、向量、矩阵

考虑一个函数

$$\text{function}(\text{input})$$

针对 function 的类型、 input 的类型，我们可以将这个函数 function 分为不同的种类。

1. function 是一个标量

我们称 function 是一个实值标量函数。用细体小写字母 f 表示。

1.1) input 是一个标量

我们称 function 的变元是标量。用细体小写字母 x 表示。

例1:

$$f(x) = x + 2$$

1.2) input 是一个向量

我们称 function 的变元是向量。用粗体小写字母 $\mathbf{x}$ 表示。

例2:

$$\text{设 } \mathbf{x} = [x_1, x_2, x_3]^T$$

$$f(\mathbf{x}) = a_1 x_1^2 + a_2 x_2^2 + a_3 x_3^2 + a_4 x_1 x_2$$

1.3) input 是一个矩阵

我们称 function 的变元是矩阵。用粗体大写字母 $\mathbf{X}$ 表示。

例3:

$$\text{设 } \mathbf{X}_{3 \times 2} = (x_{ij})_{i=1, j=1}^{3,2}$$

$$f(\mathbf{X}) = a_1 x_{11}^2 + a_2 x_{12}^2 + a_3 x_{21}^2 + a_4 x_{22}^2 + a_5 x_{31}^2 + a_6 x_{32}^2$$

2. function 是一个向量

我们称 function 是一个实向量函数。用粗体小写字母 $\mathbf{f}$ 表示。

含义: $\mathbf{f}$ 是由若干个 f 组成的一个向量。

同样地, 变元分三种: 标量、向量、矩阵。这里的符号仍与上面相同。

2.1) 标量变元

例4:

$$\mathbf{f}_{3 \times 1}(x) = \begin{bmatrix} f_1(x) \\ f_2(x) \\ f_3(x) \end{bmatrix} = \begin{bmatrix} x + 1 \\ 2x + 1 \\ 3x^2 + 1 \end{bmatrix}$$

2.2) 向量变元

例5:

$$\text{设 } \mathbf{x} = [x_1, x_2, x_3]^T$$

$$\mathbf{f}_{3 \times 1}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ f_3(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} x_1 + x_2 + x_3 \\ x_1^2 + 2x_2 + 2x_3 \\ x_1 x_2 + x_2 + x_3 \end{bmatrix}$$

2.3) 矩阵变元

例6:

$$\text{设 } \mathbf{X}_{3 \times 2} = (x_{ij})_{i=1, j=1}^{3,2}$$

$$\boldsymbol{f}_{3 \times 1}(\boldsymbol{X}) = \begin{bmatrix} f_1(\boldsymbol{X}) \\ f_2(\boldsymbol{X}) \\ f_3(\boldsymbol{X}) \end{bmatrix} = \begin{bmatrix} x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} \\ x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} + x_{11}x_{12} \\ 2x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} + x_{11}x_{12} \end{bmatrix}$$

3. function 是一个矩阵

我们称 function 是一个实矩阵函数。用粗体大写字母 $\boldsymbol{F}$ 表示。

含义： $\boldsymbol{F}$ 是由若干个 f 组成的一个矩阵。

同样地，变元分三种：标量、向量、矩阵。这里的符号仍与上面相同。

3.1) 标量变元

例7：

$$\boldsymbol{F}_{3 \times 2}(x) = \begin{bmatrix} f_{11}(x) & f_{12}(x) \\ f_{21}(x) & f_{22}(x) \\ f_{31}(x) & f_{32}(x) \end{bmatrix} = \begin{bmatrix} x + 1 & 2x + 2 \\ x^2 + 1 & 2x^2 + 1 \\ x^3 + 1 & 2x^3 + 1 \end{bmatrix}$$

3.2) 向量变元

例8：

$$\text{设 } \boldsymbol{x} = [x_1, x_2, x_3]^T$$

$$\boldsymbol{F}_{3 \times 2}(\boldsymbol{x}) = \begin{bmatrix} f_{11}(\boldsymbol{x}) & f_{12}(\boldsymbol{x}) \\ f_{21}(\boldsymbol{x}) & f_{22}(\boldsymbol{x}) \\ f_{31}(\boldsymbol{x}) & f_{32}(\boldsymbol{x}) \end{bmatrix} = \begin{bmatrix} 2x_1 + x_2 + x_3 & 2x_1 + 2x_2 + x_3 \\ 2x_1 + 2x_2 + x_3 & x_1 + 2x_2 + x_3 \\ 2x_1 + x_2 + 2x_3 & x_1 + 2x_2 + 2x_3 \end{bmatrix}$$

3.3) 矩阵变元

例9：

$$\text{设 } \boldsymbol{X}_{3 \times 2} = (x_{ij})_{i=1, j=1}^{3, 2}$$

$$\begin{aligned}
F_{3 \times 2}(\mathbf{X}) &= \begin{bmatrix} f_{11}(\mathbf{X}) & f_{12}(\mathbf{X}) \\ f_{21}(\mathbf{X}) & f_{22}(\mathbf{X}) \\ f_{31}(\mathbf{X}) & f_{32}(\mathbf{X}) \end{bmatrix} \\
&= \begin{bmatrix} x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} & 2x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} \\ 3x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} & 4x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} \\ 5x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} & 6x_{11} + x_{12} + x_{21} + x_{22} + x_{31} + x_{32} \end{bmatrix}
\end{aligned}$$

二. 矩阵求导

2.1 矩阵求导的本质

我们在高等数学中学过，对于一个多元函数

例10:

$$f(x_1, x_2, x_3) = x_1^2 + x_1x_2 + x_2x_3$$

我们可以将 f 对 x_1, x_2, x_3 的偏导分别求出来，即：

$$\begin{cases} \frac{\partial f}{\partial x_1} = 2x_1 + x_2 \\ \frac{\partial f}{\partial x_2} = x_1 + x_3 \\ \frac{\partial f}{\partial x_3} = x_2 \end{cases}$$

矩阵求导也是一样的，本质就是 function 中的每个 f 分别对变元中的每个元素逐个求偏导，只不过写成了向量、矩阵形式而已。

对于 (e.g.10)，我们把得出的3个结果写成了列向量形式：

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_{3 \times 1}} = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 + x_2 \\ x_1 + x_3 \\ x_2 \end{bmatrix}$$

一个矩阵求导以列向量形式展开的雏形就出现了。

当然我们也可以以行向量形式展开：

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_{3 \times 1}^T} = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \frac{\partial f}{\partial x_3} \right] = [2x_1 + x_2, x_1 + x_3, x_2]$$

所以，如果 function 中有 m 个 f ，变元中有 n 个元素，那么，每个 f 对变元中的每个元素逐个求偏导后，我们就会产生 $m \times n$ 个结果。

这就是矩阵求导的本质。

至于这 $m \times n$ 个结果的布局，是写成行向量，还是写成列向量，还是写成矩阵，就是我们接下来要讨论的事情。

2.2 矩阵求导的布局

不严谨地说，从直观上看：

- **分子布局**，就是分子是列向量形式，分母是行向量形式，如 (2) 式。如果这里的 function 是实向量函数 $\mathbf{f}_{2 \times 1}$ 的话，结果就是 2×3 的矩阵了：

$$\frac{\partial \mathbf{f}_{2 \times 1}(\mathbf{x})}{\partial \mathbf{x}_{3 \times 1}^T} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \frac{\partial f_1}{\partial x_3} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \frac{\partial f_2}{\partial x_3} \end{bmatrix}_{2 \times 3}$$

- **分母布局**，就是分母是列向量形式，分子是行向量形式，如 (1) 式。如果这里的 function 是实向量函数 $\mathbf{f}_{2 \times 1}$ 的话，结果就是 3×2 的矩阵了：

$$\frac{\partial \mathbf{f}_{2 \times 1}^T(\mathbf{x})}{\partial \mathbf{x}_{3 \times 1}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} \\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} \\ \frac{\partial f_1}{\partial x_3} & \frac{\partial f_2}{\partial x_3} \end{bmatrix}_{3 \times 2}$$

三. 求导法则

3.1 常数求导：

与一元函数常数求导相同：结果为零向量

$$\frac{\partial c}{\partial \mathbf{x}} = \mathbf{0}_{n \times 1}$$

其中, c 为常数。

证明:

$$\frac{\partial c}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial c}{\partial x_1} \\ \frac{\partial c}{\partial x_2} \\ \vdots \\ \frac{\partial c}{\partial x_n} \end{bmatrix} \quad (1)$$

$$= \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad (2)$$

$$= \mathbf{0}_{n \times 1} \quad (3)$$

证毕。

3.2 线性法则

与一元函数求导线性法则相同: 相加再求导等于求导再相加, 常数提外面

$$\frac{\partial [c_1 f(\mathbf{x}) + c_2 g(\mathbf{x})]}{\partial \mathbf{x}} = c_1 \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + c_2 \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

其中, c_1, c_2 为常数。

证明:

$$\frac{\partial[c_1 f(\mathbf{x}) + c_2 g(\mathbf{x})]}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial(c_1 f + c_2 g)}{\partial x_1} \\ \frac{\partial(c_1 f + c_2 g)}{\partial x_2} \\ \vdots \\ \frac{\partial(c_1 f + c_2 g)}{\partial x_n} \end{bmatrix} \quad (4)$$

$$= \begin{bmatrix} c_1 \frac{\partial f}{\partial x_1} + c_2 \frac{\partial g}{\partial x_1} \\ c_1 \frac{\partial f}{\partial x_2} + c_2 \frac{\partial g}{\partial x_2} \\ \vdots \\ c_1 \frac{\partial f}{\partial x_n} + c_2 \frac{\partial g}{\partial x_n} \end{bmatrix} \quad (5)$$

$$= c_1 \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} + c_2 \begin{bmatrix} \frac{\partial g}{\partial x_1} \\ \frac{\partial g}{\partial x_2} \\ \vdots \\ \frac{\partial g}{\partial x_n} \end{bmatrix} \quad (6)$$

$$= c_1 \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + c_2 \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \quad (7)$$

证毕。

3.3 乘积法则

与一元函数求导乘积法则相同：前导后不导 加 前不导后导

$$\frac{\partial[f(\mathbf{x})g(\mathbf{x})]}{\partial \mathbf{x}} = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x}) + f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

证明：

$$\frac{\partial[f(\mathbf{x})g(\mathbf{x})]}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial(fg)}{\partial x_1} \\ \frac{\partial(fg)}{\partial x_2} \\ \vdots \\ \frac{\partial(fg)}{\partial x_n} \end{bmatrix} \quad (8)$$

$$= \begin{bmatrix} \frac{\partial f}{\partial x_1}g + f\frac{\partial g}{\partial x_1} \\ \frac{\partial f}{\partial x_2}g + f\frac{\partial g}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n}g + f\frac{\partial g}{\partial x_n} \end{bmatrix} \quad (9)$$

$$= \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} g + f \begin{bmatrix} \frac{\partial g}{\partial x_1} \\ \frac{\partial g}{\partial x_2} \\ \vdots \\ \frac{\partial g}{\partial x_n} \end{bmatrix} \quad (10)$$

$$= \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x}) + f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \quad (11)$$

证毕。

3.4 商法则

与一元函数求导商法则相同：（上导下不导 减 上不导下导）除以（下的平方）：

$$\frac{\partial \left[\frac{f(\mathbf{x})}{g(\mathbf{x})} \right]}{\partial \mathbf{x}} = \frac{1}{g^2(\mathbf{x})} \left[\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x}) - f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \right]$$

其中， $g(\mathbf{x}) \neq 0$ 。

证明：

$$\frac{\partial \left[\frac{f(\mathbf{x})}{g(\mathbf{x})} \right]}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial(\frac{f}{g})}{\partial x_1} \\ \frac{\partial(\frac{f}{g})}{\partial x_2} \\ \vdots \\ \frac{\partial(\frac{f}{g})}{\partial x_n} \end{bmatrix} \quad (12)$$

$$= \begin{bmatrix} \frac{1}{g^2} \left(\frac{\partial f}{\partial x_1} g - f \frac{\partial g}{\partial x_1} \right) \\ \frac{1}{g^2} \left(\frac{\partial f}{\partial x_2} g - f \frac{\partial g}{\partial x_2} \right) \\ \vdots \\ \frac{1}{g^2} \left(\frac{\partial f}{\partial x_n} g - f \frac{\partial g}{\partial x_n} \right) \end{bmatrix} \quad (13)$$

$$= \frac{1}{g^2} \left(\begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} g - f \begin{bmatrix} \frac{\partial g}{\partial x_1} \\ \frac{\partial g}{\partial x_2} \\ \vdots \\ \frac{\partial g}{\partial x_n} \end{bmatrix} \right) \quad (14)$$

$$= \frac{1}{g^2(\mathbf{x})} \left[\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x}) - f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \right] \quad (15)$$

3.5 链式求导法则

1. 标量对向量的链式求导法则

设 y 是标量, $u = (u_1, u_2, \dots, u_m)^T$ 是中间向量, $x = (x_1, x_2, \dots, x_n)^T$ 是自变量向量, 且 $y = f(u)$, $u = g(x)$ 。

那么 $\frac{\partial y}{\partial x}$ 是一个 n 维向量, 其第 i 个元素为:

$$\frac{\partial y}{\partial x_i} = \sum_{j=1}^m \frac{\partial y}{\partial u_j} \frac{\partial u_j}{\partial x_i}$$

示例:

设 $y = u_1^2 + u_2$, $u_1 = x_1 + x_2$, $u_2 = 2x_1$ 。

首先, 计算偏导数:

$$\frac{\partial y}{\partial u_1} = 2u_1, \quad \frac{\partial y}{\partial u_2} = 1$$

$$\frac{\partial u_1}{\partial x_1} = 1, \quad \frac{\partial u_1}{\partial x_2} = 1, \quad \frac{\partial u_2}{\partial x_1} = 2, \quad \frac{\partial u_2}{\partial x_2} = 0$$

根据链式法则：

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial u_1} \frac{\partial u_1}{\partial x_1} + \frac{\partial y}{\partial u_2} \frac{\partial u_2}{\partial x_1} = 2u_1 \times 1 + 1 \times 2 = 2(x_1 + x_2) + 2 = 2x_1 + 2x_2 + 2$$

$$\frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial u_1} \frac{\partial u_1}{\partial x_2} + \frac{\partial y}{\partial u_2} \frac{\partial u_2}{\partial x_2} = 2u_1 \times 1 + 1 \times 0 = 2(x_1 + x_2)$$

2. 向量对向量的链式求导法则

设 $y = (y_1, y_2, \dots, y_p)^T$ 是向量, $u = (u_1, u_2, \dots, u_m)^T$ 是中间向量, $x = (x_1, x_2, \dots, x_n)^T$ 是自变量向量, 且 $y = f(u)$, $u = g(x)$ 。

那么 $\frac{\partial y}{\partial x}$ 是一个 $p \times n$ 矩阵, 其 (i, j) 元素为:

$$\frac{\partial y_i}{\partial x_j} = \sum_{k=1}^m \frac{\partial y_i}{\partial u_k} \frac{\partial u_k}{\partial x_j}$$

示例：

设：

$$y = \begin{bmatrix} u_1^2 \\ u_1 + u_2 \end{bmatrix}, \quad u = \begin{bmatrix} x_1 + x_2 \\ 2x_1 \end{bmatrix}$$

首先, 计算偏导数:

$$\frac{\partial y_1}{\partial u_1} = 2u_1, \quad \frac{\partial y_1}{\partial u_2} = 0$$

$$\frac{\partial y_2}{\partial u_1} = 1, \quad \frac{\partial y_2}{\partial u_2} = 1$$

$$\frac{\partial u_1}{\partial x_1} = 1, \quad \frac{\partial u_1}{\partial x_2} = 1, \quad \frac{\partial u_2}{\partial x_1} = 2, \quad \frac{\partial u_2}{\partial x_2} = 0$$

根据链式法则：

$$\frac{\partial y}{\partial x} = \begin{bmatrix} \frac{\partial y_1}{\partial u_1} \frac{\partial u_1}{\partial x_1} + \frac{\partial y_1}{\partial u_2} \frac{\partial u_2}{\partial x_1} & \frac{\partial y_1}{\partial u_1} \frac{\partial u_1}{\partial x_2} + \frac{\partial y_1}{\partial u_2} \frac{\partial u_2}{\partial x_2} \\ \frac{\partial y_2}{\partial u_1} \frac{\partial u_1}{\partial x_1} + \frac{\partial y_2}{\partial u_2} \frac{\partial u_2}{\partial x_1} & \frac{\partial y_2}{\partial u_1} \frac{\partial u_1}{\partial x_2} + \frac{\partial y_2}{\partial u_2} \frac{\partial u_2}{\partial x_2} \end{bmatrix}$$

代入计算可得：

$$\frac{\partial y}{\partial x} = \begin{bmatrix} 2u_1 \times 1 + 0 \times 2 & 2u_1 \times 1 + 0 \times 0 \\ 1 \times 1 + 1 \times 2 & 1 \times 1 + 1 \times 0 \end{bmatrix} = \begin{bmatrix} 2(x_1 + x_2) & 2(x_1 + x_2) \\ 3 & 1 \end{bmatrix}$$

四.矩阵求导法则的应用场景

• 神经网络中的应用：

- 在神经网络中，特别是在反向传播算法中，链式求导法则被广泛应用。例如，对于一个多层感知机（MLP），损失函数 L 关于输入数据 x 的导数计算涉及到多层的权重矩阵和激活函数。
- 假设输出层的误差向量为 δ ，权重矩阵为 W ，中间层的输出为 z ，激活函数为 σ 。
- 要计算 $\frac{\partial L}{\partial x}$ ，需要使用链式法则，从输出层逐步向前计算导数。首先计算 $\frac{\partial L}{\partial z}$ （通过 δ ），然后计算 $\frac{\partial z}{\partial x}$ （通过 W 和 σ ），最后根据链式法则：

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial z} \frac{\partial z}{\partial x}$$

- 这有助于更新网络的权重，以最小化损失函数。

• 最小二乘法中的应用：

- 最小二乘法用于拟合线性模型，通过最小化误差平方和来估计权重矩阵 W 。
- 定义：

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{pmatrix}, \quad X = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_p^T \end{pmatrix}, \quad W = \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{pmatrix}$$

其中, $x_i^T = (x_{i1} \quad x_{i2} \quad \cdots \quad x_{in})$ 。

◦ 损失函数:

$$L(w) = \sum_{i=1}^n (y_i - x_i^T \cdot w)^2 = (Y - XW)^T (Y - XW) = Y^T Y - 2Y^T XW$$

◦ 导数计算:

$$\frac{dL(W)}{dW} = -2X^T Y + 2X^T XW$$

◦ 解得权重估计:

$$\hat{W} = (X^T X)^{-1} X^T Y$$
